Capítulo 4: Armazenamento de Dados

4.1 Hierarquia de Armazenamento

Os sistemas de bases de dados lidam com grandes volumes de dados que precisam de ser armazenados de forma persistente e acedidos eficientemente. Para tal, utilizam uma **hierarquia de armazenamento** que combina diferentes tecnologias com características de velocidade, custo e volatilidade distintas [16]. Compreender esta hierarquia é fundamental para otimizar o desempenho de um SGBD.

Os principais níveis da hierarquia de armazenamento são:

A. **Memória Principal (RAM):**
   - **Características:** Muito rápida, volátil (perde o conteúdo quando a energia é desligada), custo elevado por byte.
   - **Utilização no SGBD:** Armazena dados e índices que estão a ser ativamente utilizados (buffers de dados, cache de páginas, planos de execução de consultas). É o local onde as operações de CPU são realizadas.

B. **Memória Flash (SSD - Solid State Drives):**
   - **Características:** Mais rápida que o disco magnético, não volátil, custo intermédio, maior durabilidade que discos magnéticos para algumas cargas de trabalho, mas com ciclos de escrita limitados.
   - **Utilização no SGBD:** Armazenamento de bases de dados inteiras ou partes críticas que exigem alto desempenho de I/O, como tabelas frequentemente acedidas, índices, logs de transações.

C. **Disco Magnético (HDD - Hard Disk Drives):**
   - **Características:** Não volátil, custo baixo por byte, grande capacidade, mais lento que a memória flash e RAM, suscetível a falhas mecânicas.
   - **Utilização no SGBD:** Armazenamento principal de bases de dados grandes, logs de transações, backups. A maioria dos dados persistentes reside aqui.

D. **Armazenamento Arquivo (Fitas Magnéticas, Armazenamento em Nuvem de Baixo Custo):**
   - **Características:** Muito lento, muito baixo custo por byte, grande capacidade, não volátil, ideal para armazenamento a longo prazo.
   - **Utilização no SGBD:** Backups de longo prazo, dados históricos que raramente são acedidos, conformidade regulamentar.

Tabela 4.1: Comparação da Hierarquia de Armazenamento

Característica	Memória Principal (RAM)	Memória Flash (SSD)	Disco Magnético (HDD)	Armazenamento Arquivo
Velocidade	Muito Alta	Alta	Média	Muito Baixa
Custo/Byte	Muito Alto	Alto	Baixo	Muito Baixo
Volatilidade	Volátil	Não Volátil	Não Volátil	Não Volátil
Capacidade	Baixa	Média	Alta	Muito Alta
Exemplos	DDR4, DDR5	NVMe SSD, SATA SSD	HDD 7200 RPM	Fitas LTO, S3 Glacier

4.2 Estruturas de Armazenamento Físico

Os dados numa base de dados são armazenados em ficheiros no sistema operativo, mas o SGBD organiza esses ficheiros de uma forma específica para otimizar o acesso. As unidades básicas de armazenamento são **blocos** ou **páginas** [17].

- **Bloco/Página:** A menor unidade de dados que o SGBD lê ou escreve para o disco. O tamanho típico varia entre 4KB e 64KB. A gestão eficiente de blocos é crucial para o desempenho de I/O.
- **Registos/Tuplos:** Os dados de cada linha de uma tabela são armazenados como um registo dentro de um bloco. Um bloco pode conter múltiplos registos.

4.2.1 Organização de Ficheiros de Dados

Existem várias formas de organizar os registos dentro dos ficheiros de dados:

A. **Organização Heap (Ficheiro Não Ordenado):**
   → **Descrição:** Os registos são armazenados na ordem em que são inseridos, sem qualquer ordem lógica. Novos registos são adicionados ao final do ficheiro ou em espaços vazios deixados por registos eliminados.
   → **Vantagens:** Inserções muito rápidas.
   → **Desvantagens:** Pesquisas por valor de atributo são lentas (requerem scan completo do ficheiro), atualizações e eliminações podem ser ineficientes.
   → **Uso:** Tabelas pequenas, tabelas que são frequentemente escritas mas raramente lidas na totalidade, ou como base para índices secundários.

B. **Organização Sequencial (Ficheiro Ordenado):**
   → **Descrição:** Os registos são armazenados fisicamente ordenados por um ou mais atributos (chave de ordenação). Manter a ordem requer reorganização após inserções/eliminações.

→ **Vantagens:** Pesquisas por chave de ordenação são muito eficientes (pesquisa binária), acesso sequencial rápido.

→ **Desvantagens:** Inserções e eliminações são caras, pois podem exigir a movimentação de muitos registos para manter a ordem.

→ **Uso:** Tabelas onde as consultas são frequentemente baseadas na chave de ordenação, ou para processamento em lote.

C. **Organização Hashing:**

→ **Descrição:**Os registos são distribuídos por funções de hash que mapeiam o valor de uma chave para um endereço de bloco no disco. Permite acesso direto aos registos.

→ **Vantagens:** Acesso muito rápido a registos individuais se a função de hash for bem distribuída.

→ **Desvantagens:** Ineficiente para pesquisas por intervalo ou acesso sequencial. Colisões (diferentes chaves mapeiam para o mesmo endereço) precisam ser geridas.

→ **Uso:** Bases de dados que requerem acesso rápido a registos por chave primária, como sistemas de cache ou dicionários de dados.

4.2.2 Armazenamento em Disco

Os discos rígidos (HDDs) e os SSDs são os principais dispositivos de armazenamento persistente para bases de dados. A forma como os dados são organizados e acedidos nestes dispositivos impacta diretamente o desempenho do SGBD.

- **HDDs:** Os dados são armazenados em pratos magnéticos que giram a alta velocidade. O acesso aos dados envolve o movimento de cabeças de leitura/escrita. O tempo de acesso é dominado pelo tempo de busca (seek time) e latência rotacional. Acesso sequencial é mais rápido que acesso aleatório.
- **SSDs:** Os dados são armazenados em memória flash, sem partes móveis. O acesso é eletrónico, resultando em tempos de busca e latência rotacional praticamente nulos. O acesso aleatório é significativamente mais rápido que nos HDDs. No entanto, têm um número limitado de ciclos de escrita.

O SGBD interage com o sistema de ficheiros do sistema operativo, que por sua vez gere o hardware de armazenamento. No entanto, muitos SGBD de alto desempenho podem contornar o sistema de ficheiros e aceder diretamente ao disco (raw device access) para otimizar o controlo sobre o I/O e evitar a sobrecarga do sistema operativo.

4.3 Gestão de Buffer (Buffer Manager)

O **Gestor de Buffer (Buffer Manager)** é um componente crítico do SGBD responsável por gerir a transferência de dados entre o disco e a memória principal (RAM). Como o acesso ao disco é ordens de magnitude mais lento que o acesso à RAM, o objetivo do gestor de buffer é minimizar as operações de I/O para o disco, mantendo os blocos de dados mais frequentemente acedidos na memória [18].

O gestor de buffer mantém uma área da memória principal, chamada **pool de buffers**, que contém cópias de blocos de dados do disco. Quando o SGBD precisa de um bloco de dados, ele primeiro verifica se o bloco já está no pool de buffers. Se estiver (cache hit), o acesso é rápido. Se não estiver (cache miss), o gestor de buffer lê o bloco do disco para o pool de buffers, substituindo um bloco existente se o pool estiver cheio.

Políticas de Substituição de Blocos

Para decidir qual bloco remover do pool de buffers quando este está cheio, o gestor de buffer utiliza políticas de substituição, como:

- **LRU (Least Recently Used):** Remove o bloco que foi acedido há mais tempo. É uma política comum e geralmente eficaz.
- **FIFO (First-In, First-Out):** Remove o bloco que está há mais tempo no pool de buffers.
- **Clock Policy:** Uma variação da LRU que é mais eficiente de implementar.
- **MRU (Most Recently Used):** Remove o bloco que foi acedido mais recentemente. Pode ser útil em cenários de scan sequencial.

Write-Ahead Logging (WAL)

Para garantir a durabilidade dos dados em caso de falha, muitos SGBD utilizam a técnica **Write-Ahead Logging (WAL)**. Antes de qualquer alteração a um bloco de dados ser escrita para o disco, a alteração correspondente é registada num **log de transações** (também no disco). Isto garante que, mesmo que o sistema falhe antes de o bloco de dados ser gravado, a alteração pode ser recuperada a partir do log durante a recuperação [19].

4.4 RAID (*Redundant Array of Independent Disks*)

RAID é uma tecnologia que combina múltiplos discos físicos num único volume lógico para melhorar o desempenho, a redundância ou ambos. Existem vários níveis de RAID, cada um com diferentes compromissos entre custo, desempenho e tolerância a falhas [20].

Níveis de RAID Comuns:

- **RAID 0 (*Striping*):** Os dados são divididos em blocos e distribuídos por vários discos. Melhora o desempenho de I/O, mas não oferece redundância. Se um disco falhar, todos os dados são perdidos.
- **RAID 1 (*Mirroring*):** Os dados são duplicados (espelhados) em dois ou mais discos. Oferece alta redundância (tolerância a falhas de um disco), mas o custo é elevado (o dobro do armazenamento necessário) e o desempenho de escrita pode ser ligeiramente inferior.
- **RAID 5 (*Striping with Parity*):** Os dados são distribuídos por vários discos, e um bloco de paridade é gerado e distribuído pelos discos. Oferece um bom equilíbrio entre desempenho, capacidade e redundância (pode tolerar a falha de um disco). Requer pelo menos 3 discos.
- **RAID 6 (*Striping with Double Parity*):** Semelhante ao RAID 5, mas com dois blocos de paridade distribuídos. Pode tolerar a falha de até dois discos. Requer pelo menos 4 discos, com maior sobrecarga de escrita.
- **RAID 10 (RAID 1+0):** Uma combinação de RAID 1 e RAID 0. Os dados são espelhados e depois distribuídos. Oferece alto desempenho e alta redundância (pode tolerar a falha de múltiplos discos, desde que não sejam do mesmo par espelhado). É caro, pois requer o dobro do armazenamento.

Tabela 4.2: Comparação de Níveis de RAID

Nível RAID	Descrição	Vantagens	Desvantagens	Discos Mínimos
RAID 0	*Striping*	Alto desempenho de I/O	Sem redundância	2
RAID 1	*Mirroring*	Alta redundância	Custo elevado (50% de capacidade)	2
RAID 5	*Striping* com Paridade Distribuída	Bom equilíbrio, tolerância a 1 falha	Desempenho de escrita impactado	3
RAID 6	*Striping* com Dupla Paridade	Tolerância a 2 falhas	Maior sobrecarga de escrita	4
RAID 10	*Striping* e *Mirroring*	Alto desempenho e alta redundância	Muito caro (50% de capacidade)	4

4.5 Exemplo: Configuração de Armazenamento e Impacto no Desempenho

Consideremos um cenário onde precisamos de otimizar o armazenamento para um SGBD. A escolha do tipo de disco e da configuração RAID é crucial.

4.5.1 Cenário: Servidor de Base de Dados para uma Aplicação de Comércio Eletrónico

Uma aplicação de comércio eletrónico tem as seguintes características:

- **Transações de escrita intensivas:** Inserção de novas encomendas, atualização de stock, registo de utilizadores.
- **Consultas de leitura frequentes:** Pesquisa de produtos, histórico de encomendas, perfis de utilizadores.
- **Necessidade de alta disponibilidade e durabilidade de dados.**

Configuração Sugerida:

A. **Logs de Transações:** Devem ser armazenados em SSDs dedicados, preferencialmente em RAID 1, para garantir alta velocidade de escrita e durabilidade em caso de falha de disco. O WAL exige que os logs sejam escritos de forma síncrona e rápida.
B. **Ficheiros de Dados (Tabelas e Índices):** Para as tabelas mais acedidas e índices críticos, SSDs em RAID 10 seriam ideais. O RAID 10 oferece um excelente desempenho de leitura e escrita, além de alta redundância. Para tabelas menos críticas ou dados históricos, HDDs em RAID 5 ou RAID 6 poderiam ser utilizados para otimizar o custo por capacidade.
C. **TempDB (SQL Server) / Temporary Tables (*MySQL*):** Para bases de dados temporárias ou ficheiros de trabalho, SSDs locais (sem RAID, se a perda de dados temporários for aceitável) podem ser usados para maximizar o desempenho, pois estes dados não precisam de ser persistentes após um reinício.
D. **Backups:** Armazenamento em HDDs de alta capacidade (RAID 5 ou 6) para backups diários, e armazenamento arquivo para backups de longo prazo.

Impacto no Desempenho:

- ***SSDs* para *Logs* e Dados Ativos:** Reduzem drasticamente a latência de I/O, acelerando as operações de escrita (commit de transações) e leitura (consultas). Isto é vital para uma aplicação transacional de alto volume.
- **RAID 1/10 para Redundância:** Garante que a aplicação continue a funcionar mesmo com a falha de um ou mais discos, minimizando o tempo de inatividade (downtime).
- **Gestão de Buffer Otimizada:** Um pool de buffers bem dimensionado e políticas de substituição eficientes reduzem a necessidade de aceder ao disco, mantendo os dados quentes na RAM.

4.6 Exercícios

A. **Questão:** Compare e contraste as características de velocidade, custo, volatilidade e capacidade da Memória Principal, Memória Flash e Disco Magnético. Dê exemplos de como cada um é utilizado num SGBD.

B. **Questão:** Explique o conceito de bloco/página de dados num SGBD. Porque é que o tamanho do bloco é uma decisão importante no design de um SGBD?

C. **Questão:** Descreva as três principais organizações de ficheiros de dados (*Heap, Sequencial, Hashing*). Para cada uma, discuta as suas vantagens, desvantagens e cenários de uso ideais.

D. **Questão:** Qual é o papel do Gestor de Buffer num SGBD? Explique como a política de substituição LRU funciona e por que é amplamente utilizada. O que é Write-Ahead Logging e qual a sua importância?

E. **Questão:** Explique os níveis de RAID 0, RAID 1, RAID 5 e RAID 10. Para cada nível, discuta o número mínimo de discos necessários, as suas vantagens em termos de desempenho e redundância, e as suas desvantagens.